

# 统计学习方法：

## 那些你应该知道的基础知识

讲师：K

---

# 基础知识

## 快速回顾



注意：

我们这门课的重点并不是学习上述的这些内容，但是我们需要一些基础的知识。

使用方法建议：

需要了解的知识请及时翻看上面的内容~

# 线性代数

## 向量和矩阵



➤ 向量和矩阵的表达形式:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1d} \\ a_{21} & a_{22} & \dots & a_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nd} \end{bmatrix}$$

➤ 点乘的理解:

$$\mathbf{w} \bullet \mathbf{x} = \sum_{i=1}^n w_i x_i$$

➤ 对于几何的理解:

向量在N维空间的夹角↓

$$\mathbf{w} \bullet \mathbf{x} = |\mathbf{w}| |\mathbf{x}| \cos(\theta)$$

# 微积分

➤ 对于  $y = f(x)$ :

偏导  $\frac{dy}{dx}$  是梯度或者斜率

积分是  $\int_{x=a}^{x=b} f(x) dx$  是曲线下的面积

➤ 对于多变量的功能  $y = f(x_1, x_2, \dots, x_p)$

偏导  $\frac{\partial f}{\partial x_i}$ , 对  $x$  求导假设其他变量都保持不变

梯度向量表示为:

$$\nabla f = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{pmatrix}$$

# 最优化理论



- 不受约束的最优化:  $\min f(\mathbf{x})$
- 受约束的最优化:

$$\begin{aligned} \min f(\mathbf{x}) \\ \text{subject to } g_i(\mathbf{x}) \leq b_i, \quad i = 1, 2, \dots, m \end{aligned}$$

- 梯度和海森矩阵:

$$\nabla f = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{pmatrix} \quad H = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_p} \\ \vdots & \vdots & \cdots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \frac{\partial^2 f}{\partial x_p \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{bmatrix}$$

- 梯度下降理论:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \eta \nabla f$$

- 牛顿法:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - H^{-1} \nabla f$$

- 拉格朗日乘数:

$$\begin{aligned} \min f(\mathbf{x}) \\ \text{subject to } g_i(\mathbf{x}) \leq b_i, \quad i = 1, 2, \dots, m \\ F(\mathbf{x}, \lambda) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i [b_i - g_i(\mathbf{x})] \end{aligned}$$



# 概率论

## 单变量VS多变量



➤ 离散概率:  $P[X]$

➤ 连续概率密度:  $p(x)$

➤ 联合概率:  $P[X, Y]$

➤ 条件概率:  $P[X|Y]$

➤ 单变量高斯分布:

➤ 多变量高斯分布:

$$\begin{aligned}P[Y|X] &= \frac{P[X|Y] P[Y]}{P[X]} \\P[X] &= \sum_Y P[X|Y] P[Y] \\P[X, Y] &= P[X|Y] P[Y] \\P[X] &= \sum_y P[X, Y] \\&= \sum_Y P[X|Y] P[Y]\end{aligned}$$

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2} \frac{(x-m)^2}{\sigma^2}\right\}$$

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{p/2}(\det \mathbf{C})^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mathbf{m})^t \mathbf{C}^{-1}(\mathbf{x} - \mathbf{m})\right\}$$

M表示平均值, 是向量;  
C代表协方差矩阵, 它是对称半正定矩阵



**deepshare.net**

深享网

联系我们：

电话：18001992849

邮箱：service@deepshare.net

QQ：2677693114



公众号



客服微信

